NetApp AFF A400 mit Lenovo ThinkSystem SR670 V2 für KI- und ML-Modelltraining

NetApp Solutions

NetApp
March 19, 2024

This PDF was generated from https://docs.netapp.com/de-de/netapp-solutions/ai/a400-thinksystem-introduction.html on March 19, 2024. Always check docs.netapp.com for the latest.

Inhalt

NetApp AFF A400 mit Lenovo ThinkSystem SR670 V2 für KI- und ML-Modelltraining . . . 1
TR-4810: NetApp AFF A400 mit Lenovo ThinkSystem SR670 V2 für KI- und ML-Modelltraining . . . 1
Technologieüberblick . . . 2
Testplan . . . 7
Testergebnisse . . . 7
Testkonfiguration . . . 8
Testverfahren und detaillierte Ergebnisse . . . 9
Anpassungen der Architektur . . . 12
Schlussfolgerung . . . 12

NetApp AFF A400 mit Lenovo ThinkSystem SR670 V2 für KI- und ML-Modelltraining

TR-4810: NetApp AFF A400 mit Lenovo ThinkSystem SR670 V2 für KI- und ML-Modelltraining

Sathish Thyagarajan, David Arnette, NetApp Mircea Troaca, Lenovo

Diese Lösung bietet eine Midrange-Cluster-Architektur und nutzt NetApp Storage und Lenovo Server, die für KI-Workloads (künstliche Intelligenz) optimiert sind. Geeignet für kleine und mittelständische Unternehmen, bei denen die meisten Computing-Aufgaben ein Node (eine einzelne oder mehrere GPUs) sind oder über einige Compute-Nodes verteilt werden. Diese Lösung lässt sich für viele Unternehmen an den meisten täglichen KI-Trainingsaufgaben anpassen.

Dieses Dokument behandelt Tests und Validierungen einer Computing- und Storage-Konfiguration, die aus Lenovo SR670V2 Servern mit acht GPUs, einem Midrange-System von NetApp AFF A400 und einem 100-GbE-Interconnect-Switch besteht. Zur Messung der Performance haben wir ResNet50 mit dem ImageNet-Datensatz, einer Batch-Größe von 408, Half Precision, CUDA und cuDNN verwendet. Diese Architektur ist eine effiziente und kostengünstige Lösung für kleine und mittelständische Unternehmen. Sie startet mit KI-Initiativen, die die Funktionen der Enterprise-Klasse von NetApp ONTAP Storage mit Cloud-Integration benötigen.

Zielgruppe

Dieses Dokument richtet sich an folgende Zielgruppen:

- Data Scientists, Data Engineers, Datenadministratoren und Entwickler von KI-Systemen
- Enterprise-Architekten, die Lösungen für die Entwicklung von KI-Modellen entwickeln
- Data Scientists und Data Engineers, die nach effizienten Möglichkeiten suchen, Entwicklungsziele für Deep Learning (DL) und Machine Learning (ML) zu erreichen
- Führungskräfte aus Unternehmen und Entscheidungsträger für OT/IT, die eine möglichst schnelle Markteinführungszeit für KI-Initiativen erreichen möchten

Lösungsarchitektur

Diese Lösung mit Lenovo ThinkSystem Servern und NetApp ONTAP mit AFF Storage wurde entwickelt, um KI-Training auf großen Datensätzen unter Verwendung der Rechenleistung von GPUs neben herkömmlichen CPUs zu ermöglichen. Diese Validierung belegt eine hohe Performance und ein optimales Datenmanagement mit einer Scale-out-Architektur, in der ein, zwei oder vier Lenovo SR670 V2 Server zusammen mit einem einzigen NetApp AFF A400 Storage-System eingesetzt werden. Die folgende Abbildung bietet einen Überblick über die Architektur.

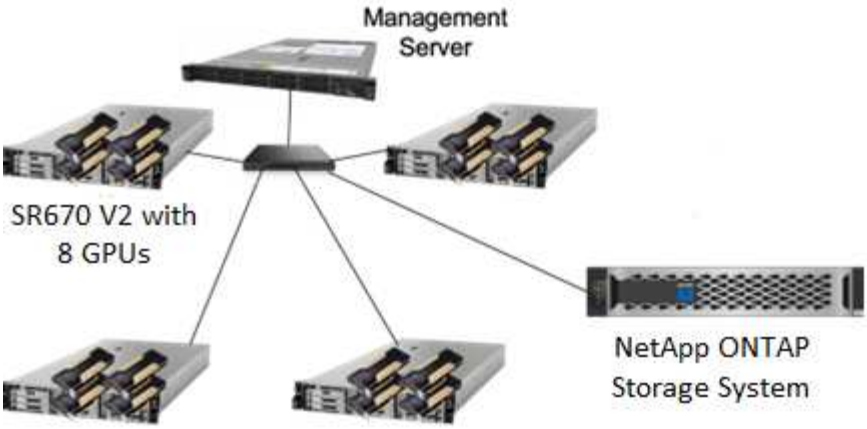

Diese Lösung von NetApp und Lenovo bietet folgende wichtige Vorteile:

- Hocheffiziente und kostengünstige Leistung bei der parallelen Ausführung mehrerer Schulungsjobs
- Skalierbare Performance basierend auf einer unterschiedlichen Anzahl von Lenovo Servern und verschiedenen Modellen von NetApp Storage Controllern
- Robuste Datensicherung zur Einhaltung niedriger Recovery-Zeitpunkte (RPOs) und Recovery-Zeiten (RTOs) ohne Datenverluste
- Optimiertes Datenmanagement mit Snapshots und Klonen zur Optimierung von Entwicklungs-Workflows

Technologieüberblick

In diesem Abschnitt werden die Hauptkomponenten dieser Lösung genauer erläutert.

NetApp AFF Systeme

Mit NetApp AFF Storage-Systemen erfüllen Unternehmen Enterprise-Storage-Anforderungen mit branchenführender Performance, überlegener Flexibilität, Cloud-Integration und erstklassigem Datenmanagement. AFF Systeme wurden speziell für Flash entwickelt. Sie helfen geschäftskritische Daten zu beschleunigen, zu managen und zu schützen.

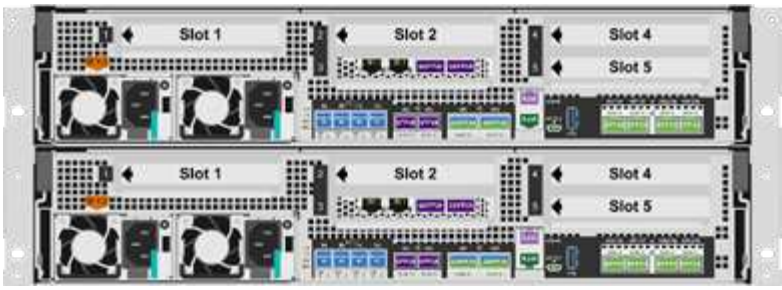

Die NetApp AFF A400 ist ein Midrange-NVMe-Flash-Storage-System mit folgenden Merkmalen:

- Maximale effektive Kapazität: ~20 PB
- Maximale horizontale Skalierbarkeit: 2-24 Nodes (12 HA-Paare)
- Unterstützung für 25-GbE- und 16-GB-FC-Host
- 100-GbE-RDMA over Converged Ethernet (RoCE)-Konnektivität für NVMe-Erweiterungs-Storage-Shelfs
- 100-GbE-RoCE-Ports können für die Host-Netzwerk-Anbindung verwendet werden, wenn NVMe-Shelfs nicht angeschlossen sind
- Komplette Storage Shelves zur Erweiterung der 12 Gbit/s-SAS-Konnektivität
- In zwei Konfigurationen erhältlich:
  - Ethernet: 4x 25-GB-Ethernet (SFP28)-Ports
  - Fibre Channel: 4 16-Gbit-FC-Ports (SFP+)
- 100 % 8 KB zufälliger Lesezugriff @0,4 ms 400.000 IOPS

Die NetApp AFF A250 Funktionen für KI/ML-Implementierungen der Einstiegsklasse umfassen Folgendes:

- Maximale effektive Kapazität: 35 PB
- Maximale horizontale Skalierbarkeit: 2-24 Nodes (12 HA-Paare)
- 440.000 IOPS zufälliger Lesezugriff @1 ms
- Basiert auf dem neuesten NetApp ONTAP-Release ONTAP 9.8 oder höher
- Zwei 25-GB-Ethernet-Ports für HA und Cluster Interconnect

NetApp bietet auch andere Storage-Systeme wie AFF A800 und AFF A700 an, die eine höhere Performance und Skalierbarkeit für größere KI/ML-Implementierungen bieten.

NetApp ONTAP

ONTAP 9, die jüngste Generation der Storage-Managementsoftware von NetApp, ermöglicht Unternehmen eine Modernisierung der Infrastruktur und den Übergang zu einem Cloud-fähigen Datacenter. Dank der erstklassigen Datenmanagementfunktionen lassen sich mit ONTAP sämtliche Daten mit einem einzigen Toolset managen und schützen, ganz gleich, wo sich diese Daten befinden. Genauso können die Daten problemlos dorthin verschoben werden, wo sie benötigt werden: Zwischen Edge, Core und Cloud. ONTAP 9 umfasst zahlreiche Funktionen, die das Datenmanagement vereinfachen, geschäftskritische Daten beschleunigen und schützen und die Infrastruktur über Hybrid-Cloud-Architekturen hinweg zukunftssicher machen.

Vereinfachtes Datenmanagement

Für den Enterprise-IT-Betrieb spielt Datenmanagement eine zentrale Rolle, da es Applikationen und

Datensätzen die richtigen Ressourcen zuweist. ONTAP umfasst die folgenden Funktionen, um den Betrieb zu optimieren und zu vereinfachen und damit die Gesamtbetriebskosten zu senken:

- **Inline-Data-Compaction und erweiterte Deduplizierung.** Data-Compaction reduziert den ungenutzten Speicherplatz in Storage-Blöcken, während Deduplizierung die effektive Kapazität deutlich steigert. Dies gilt für lokal gespeicherte Daten und für Daten-Tiering in die Cloud.
- **Minimum, Maximum und anpassungsfähige Quality of Service (QoS)** durch granulare QoS-Kontrollen können geschäftskritische Applikationen auch in hochgemeinsam genutzten Umgebungen weiterhin Performance-Level aufrechterhalten.
- **ONTAP FabricPool.** mit dieser Funktion werden kalte Daten automatisch in Public- und Private-Cloud-Storage-Optionen verschoben, einschließlich Amazon Web Services (AWS), Azure und NetApp StorageGRID Objekt-Storage.

Beschleunigung und Sicherung von Daten

ONTAP bietet überdurchschnittliche Performance und Datensicherung, erweitert diese Funktionen auf folgende Weise:

- **Performance und geringere Latenz.** ONTAP bietet den höchstmöglichen Durchsatz bei geringstmöglicher Latenz.
- **Datensicherung.** ONTAP bietet integrierte Datensicherungsfunktionen mit einem einheitlichen Management über alle Plattformen hinweg.
- **NetApp Volume Encryption.** ONTAP bietet native Verschlüsselung auf Volume-Ebene mit integriertem und externem Verschlüsselungsmanagement.

Zukunftssichere Infrastruktur

ONTAP 9 hilft Unternehmen dabei, flexibel auf ständig wechselnde Geschäftsanforderungen zu reagieren:

- **Nahtlose Skalierung und unterbrechungsfreier Betrieb.** ONTAP unterstützt das unterbrechungsfreie Hinzufügen von Kapazitäten zu bestehenden Controllern sowie das Scale-out von Clustern. Kunden können Upgrades auf die neuesten Technologien wie NVMe und 32 GB FC ohne teure Datenmigrationen oder Ausfälle durchführen.
- **Cloud Connection.** ONTAP ist die Storage-Managementsoftware mit der umfassendsten Cloud-Integration und bietet Optionen für softwaredefinierten Storage (ONTAP Select) und Cloud-native Instanzen (NetApp Cloud Volumes Service) in allen Public Clouds.
- **Integration in moderne Applikationen.** ONTAP bietet Datenservices der Enterprise-Klasse für Plattformen und Applikationen der neuesten Generation, wie OpenStack, Hadoop und MongoDB, auf derselben Infrastruktur, die bereits vorhandene Unternehmensanwendungen unterstützt.

NetApp FlexGroup Volumes

Trainingsdatensätze sind in der Regel eine Sammlung von möglicherweise Milliarden Dateien. Dateien können Text, Audio, Video und andere Formen unstrukturierter Daten enthalten, die gespeichert und verarbeitet werden müssen, damit sie gleichzeitig gelesen werden können. Das Storage-System muss zahlreiche kleine Dateien speichern und diese parallel für sequenzielle und zufällige I/O lesen

Ein FlexGroup Volume (die folgende Abbildung) ist ein einziger Namespace, der aus mehreren zusammengehörigen Member Volumes besteht, wie ein NetApp FlexVol Volume für Storage-Administratoren gemanagt wird und sich auch so verhält. Dateien in einem FlexGroup Volume werden Volumes einzelner Mitglieder zugewiesen und nicht über Volumes oder Nodes verteilt. Sie bieten folgende Möglichkeiten:

- Bis zu 20 Petabyte Kapazität und planbare niedrige Latenz für Workloads mit vielen Metadaten
- Bis zu 400 Milliarden Dateien im selben Namespace
- Parallelisierte Vorgänge bei NAS-Workloads über CPUs, Nodes, Aggregate und zusammengehörige FlexVol Volumes hinweg

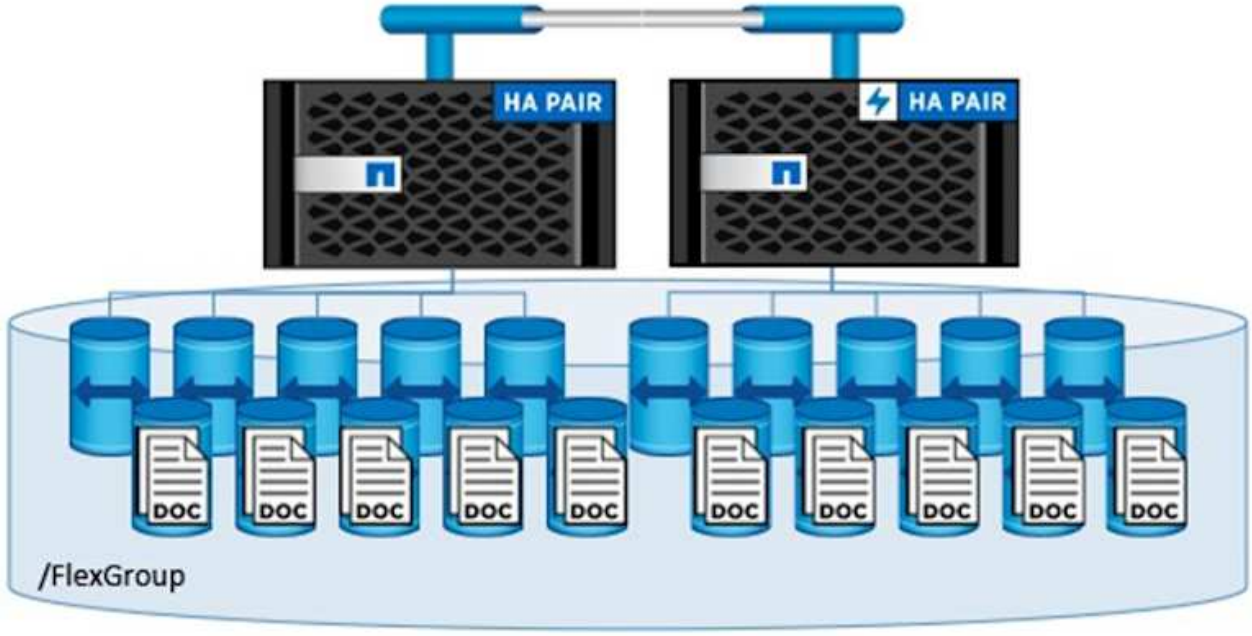

”

Lenovo ThinkSystem-Portfolio

Lenovo ThinkSystem Server verfügen über innovative Hardware, Software und Services, die die Herausforderungen der Kunden von heute lösen und einen evolutionären, zweckbezogenen, modularen Designansatz bieten, um den Herausforderungen von morgen gerecht zu werden. Diese Server profitieren von erstklassigen, Industriestandard-Technologien in Verbindung mit differenzierten Lenovo Innovationen, um die größtmögliche Flexibilität bei x86-Servern zu bieten.

Zu den wichtigsten Vorteilen der Bereitstellung von Lenovo ThinkSystem-Servern gehören:

- Hochskalierbare, modulare Designs, die mit Ihrem Unternehmen wachsen
- Branchenführende Ausfallsicherheit und dadurch Zeitersparnis von Stunden mit teuren, ungeplanten Ausfallzeiten
- Schnelle Flash-Technologien für kürzere Latenzen, schnellere Reaktionszeiten und intelligentes Datenmanagement in Echtzeit

Im KI-Bereich verfolgt Lenovo einen praktischen Ansatz, der Unternehmen dabei hilft, die Vorteile VON ML und KI für ihre Workloads zu verstehen und einzuführen. Lenovo Kunden können die KI-Angebote von Lenovo in Lenovo AI Innovation Centers testen und auswerten, um den Wert für ihren jeweiligen Anwendungsfall zu verstehen. Dieser kundenorientierte Ansatz bietet Kunden Machbarkeitsstudien für Entwicklungsplattformen, die sofort einsatzbereit und für KI optimiert sind, um die Amortisierung zu beschleunigen.

Lenovo SR670 V2

Der Lenovo ThinkSystem SR670 V2 Rack-Server bietet optimale Leistung für beschleunigte KI und High-

Performance Computing (HPC). Der SR670 V2 unterstützt bis zu acht GPUs und eignet sich für die rechenintensiven Workload-Anforderungen von ML, DL und Inferenz.

4x SXM GPUs with 8x 2.5-inch HS drives and 2x PCIe I/O slots

4x double-wide or 8x single-wide GPU slots and 2x PCIe I/O slots with 8x 2.5-inch or 4x 3.5-inch HS drives

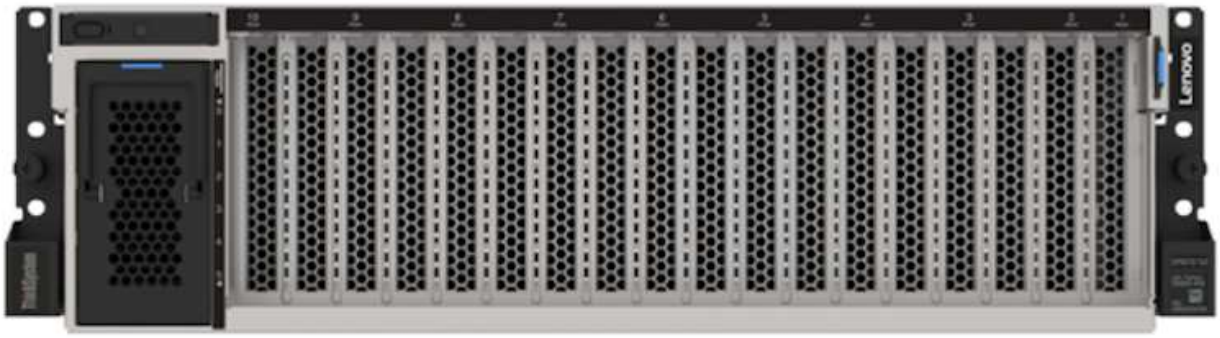

8x double-wide GPU slots with 6x EDSFF HS drives and 2x PCIe I/O slots

Mit den neuesten skalierbaren Intel Xeon CPUs, die High-End-GPUs unterstützen (einschließlich der NVIDIA A100 80 GB PCIe 8x GPU), liefert das ThinkSystem SR670 V2 eine optimierte und beschleunigte Performance für KI- und HPC-Workloads.

Da mehr Workloads die Performance von Beschleunigern nutzen, hat sich auch der Bedarf an GPU-Dichte erhöht. Branchen wie Einzelhandel, Finanzdienstleistungen, Energie und Gesundheitswesen nutzen GPUs, um mit ML-, DL- und Inferenztechniken mehr Einblicke zu gewinnen und Innovationen zu fördern.

Das ThinkSystem SR670 V2 ist eine optimierte Lösung der Enterprise-Klasse für die Bereitstellung von beschleunigten HPC- und KI-Workloads in der Produktion. Dadurch wird die Systemperformance maximiert und gleichzeitig die Dichte des Rechenzentrums für Supercomputing-Cluster mit Plattformen der nächsten Generation aufrechterhalten.

Weitere Funktionen sind:

- Unterstützung von GPU-Direct RDMA-I/O, bei dem High-Speed-Netzwerkadapter direkt mit den GPUs verbunden sind, um die I/O-Performance zu maximieren.
- Unterstützung von GPU-Direct-Storage, in dem NVMe-Laufwerke direkt mit den GPUs verbunden sind, um die Storage-Performance zu maximieren.

MLPerf

MLPerf ist eine branchenführende Benchmark-Suite zur Evaluierung der KI-Performance. In dieser Validierung verwendeten wir seinen Image-Klassifizierungs-Benchmark mit MXNet, einem der beliebtesten KI-Frameworks. Das MXNet_Benchmarks-Trainingsskript wurde für das KI-Training verwendet. Das Skript enthält Implementierungen von mehreren gängigen konventionellen Modellen und ist so schnell wie möglich konzipiert. Sie kann auf einem einzelnen Rechner ausgeführt oder im verteilten Modus auf mehreren Hosts ausgeführt werden.

Testplan

In dieser Validierung haben wir das von MLPerf v2.0 festgelegte Image Recognition Training durchgeführt. Insbesondere haben wir das Modell ResNet v2.0 mit dem ImageNet-Datensatz trainiert, bis wir eine Genauigkeit von 76.1 % erreicht haben. Die Hauptmetrik ist die Zeit, bis die gewünschte Genauigkeit erreicht ist. Wir berichten außerdem über die Trainingsbandbreite in Bildern pro Sekunde, um die horizontal skalierbare Effizienz besser beurteilen zu können.

Im primären Testfall wurden mehrere unabhängige Trainingsprozesse (eine pro Node) gleichzeitig bewertet. Dies simuliert den Hauptanwendungsfall, ein Shared-System, das von mehreren Data Scientists genutzt wird. Im zweiten Testfall wurde die horizontale Skalierbarkeit evaluiert.

Testergebnisse

Die folgende Tabelle fasst die Ergebnisse aller Tests zusammen, die bei dieser Lösung durchgeführt wurden.

Testbeschreibung	Zusammenfassung der Ergebnisse
Schulung zur Bilderkennung: Mehrere gleichzeitige Jobs	Hocheffiziente Performance: Alle Jobs wurden bei voller Geschwindigkeit ausgeführt, auch wenn der Cluster voll genutzt wurde. Die NetApp Storage-Systeme lieferten eine vergleichbar hohe Trainings-Performance wie bei lokalem SSD-Storage. Gleichzeitig konnten Daten einfach zwischen Servern gemeinsam genutzt werden.

Testbeschreibung	Zusammenfassung der Ergebnisse
Training zur Bilderkennung: Horizontal skalieren	Äußerst effizient für bis zu vier Nodes. An diesem Punkt war eine horizontale Skalierung weniger effizient, aber trotzdem machbar. Die Verwendung eines schnelleren Computational Networks verbessert die Skalierbarkeit. Die Trainings-Performance des NetApp Storage-Systems war mit der lokalen SSD-Storage vergleichbar, während gleichzeitig die gemeinsame Nutzung von Daten zwischen Servern ermöglicht wurde.

Testkonfiguration

In diesem Abschnitt werden die getesteten Konfigurationen, die Netzwerkinfrastruktur, der SR670 V2 Server und Details zur Storage-Bereitstellung von NetApp beschrieben.

Lösungsarchitektur

Für diese Validierung wurden die in der folgenden Tabelle aufgeführten Lösungskomponenten verwendet.

Lösungskomponenten	Details
Lenovo ThinkSystem-Server	• Zwei SR670 V2 Server mit jeweils acht NVIDIA A100 80 GB GPU-Karten • Jeder Server enthält 2 Intel Xeon Platinum 8360Y CPUs (28 physische Kerne) und 1 TB RAM
Linux (Ubuntu – 20.04 mit CUDA 11.8)	
NetApp AFF Storage-System (HA-Paar)	• NetApp ONTAP 9.10.1 Software • 24 x 960-GB-SSDs • NFS-Protokoll • 1 Schnittstellengruppe (iffrp) pro Controller, mit vier logischen IP-Adressen für Mount-Punkte

In dieser Validierung haben wir ResNet v2.0 mit dem von MLPerf v2.0 angegebenen ImageNet-Basissatz verwendet. Der Datensatz wird mithilfe des NFS-Protokolls in einem NetApp AFF Storage-System gespeichert. Die SR670s waren über einen 100-GbE-Switch mit dem NetApp AFF A400 Storage-System verbunden.

ImageNet ist ein häufig verwendeter Bilddatensatz. Es enthält fast 1.3 Millionen Bilder für eine Gesamtgröße von 144 GB. Die durchschnittliche Bildgröße beträgt 108 KB.

Die folgende Abbildung zeigt die Netzwerktopologie der getesteten Konfiguration.

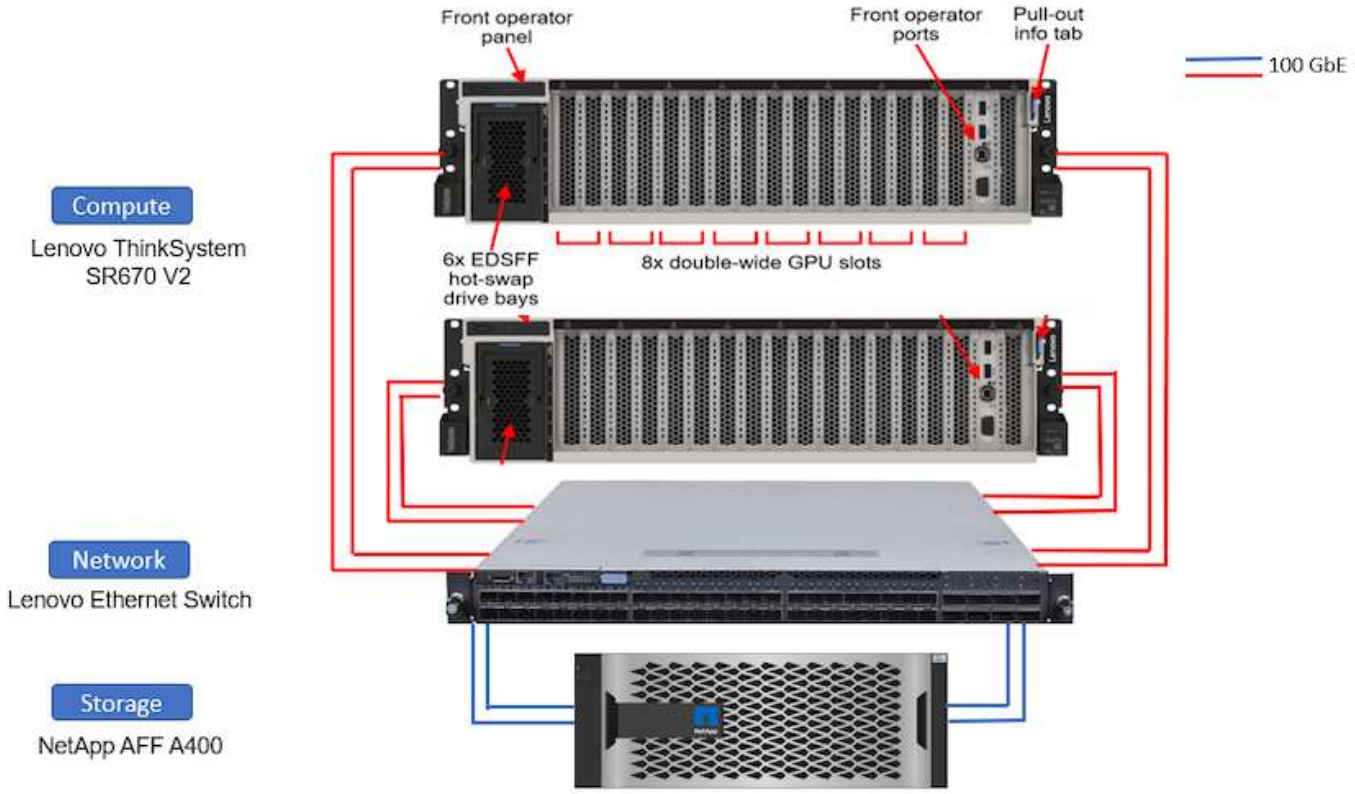

Storage Controller

In der folgenden Tabelle wird die Storage-Konfiguration aufgeführt.

Controller	Aggregat	FlexGroup Volume	Aggregatgröße	Volume-Größe	Bereitstellungspunkt für Betriebssystem
Kontroller1	Aggr. 1	/a400-100g	9,9 TB	19 TB	/a400-100g
Controller 2	Aggr. 2	/a400-100g	9,9 TB		/a400-100g

Der Ordner /a400-100g enthält den Datensatz, der für die ResNet-Validierung verwendet wird.

Testverfahren und detaillierte Ergebnisse

In diesem Abschnitt werden die Ergebnisse der detaillierten Testverfahren beschrieben.

Image-Recognition-Training mit ResNet in ONTAP

Wir führten den ResNet50 Benchmark mit einem und zwei SR670 V2 Servern aus. Bei diesem Test wurde der MXNet 22.04-py3 NGC-Container verwendet.

Bei dieser Validierung haben wir folgendes Testverfahren verwendet:

1. Wir haben den Host-Cache vor dem Ausführen des Skripts gelöscht, um sicherzustellen, dass die Daten nicht bereits im Cache gespeichert waren:

```
sync ; sudo /sbin/sysctl vm.drop_caches=3
```

2. Wir haben das Benchmark-Skript mit dem ImageNet Datensatz im Server-Storage (lokale SSD-Speicherung) sowie auf dem NetApp AFF Storage-System ausgeführt.
3. Wir validierten die Netzwerk- und lokale Storage-Performance mithilfe des `dd` Befehl.
4. Für die Ausführung des Single-Node haben wir den folgenden Befehl verwendet:

```
python train_imagenet.py --gpus 0,1,2,3,4,5,6,7 --batch-size 408 --kv
-store horovod --lr 10.5 --mom 0.9 --lr-step-epochs pow2 --lars-eta
0.001 --label-smoothing 0.1 --wd 5.0e-05 --warmup-epochs 2 --eval-period
4 --eval-offset 2 --optimizer sgdwfastlars --network resnet-v1b-stats-fl
--num-layers 50 --num-epochs 37 --accuracy-threshold 0.759 --seed 27081
--dtype float16 --disp-batches 20 --image-shape 4,224,224 --fuse-bn-relu
1 --fuse-bn-add-relu 1 --bn-group 1 --min-random-area 0.05 --max-random
-area 1.0 --conv-algo 1 --force-tensor-core 1 --input-layout NHWC --conv
-layout NHWC --batchnorm-layout NHWC --pooling-layout NHWC --batchnorm
-mom 0.9 --batchnorm-eps 1e-5 --data-train /data/train.rec --data-train
-idx /data/train.idx --data-val /data/val.rec --data-val-idx
/data/val.idx --dali-dont-use-mmap 0 --dali-hw-decoder-load 0 --dali
-prefetch-queue 5 --dali-nvjpeg-memory-padding 256 --input-batch
-multiplier 1 --dali- threads 6 --dali-cache-size 0 --dali-roi-decode 1
--dali-preallocate-width 5980 --dali-preallocate-height 6430 --dali-tmp
-buffer-hint 355568328 --dali-decoder-buffer-hint 1315942 --dali-crop
-buffer-hint 165581 --dali-normalize-buffer-hint 441549 --profile 0
--e2e-cuda-graphs 0 --use-dali
```

5. Für die verteilten Läufe haben wir das Parallelisierungsmodell des Parameterservers verwendet. Wir haben zwei Parameter-Server pro Node verwendet und die Anzahl der Epoch-Durchläufe auf die gleiche Weise festgelegt wie auf dem Single-Node-Betrieb. Unser Ziel war, da verteiltes Training aufgrund unperfekter Synchronisierung zwischen Prozessen oft mehr Epochen benötigt. Die unterschiedliche Anzahl von Epoch-Durchläufen kann Vergleiche zwischen Single-Node- und verteilten Fällen verzerren.

Lesegeschwindigkeit von Daten: Lokal statt Netzwerkspeicher

Die Lesegeschwindigkeit wurde mit dem getestet `dd` Befehl für eine der Dateien für den ImageNet-Datensatz. Konkret haben wir folgende Befehle sowohl für lokale als auch für Netzwerkdaten ausgeführt:

```
sync ; sudo /sbin/sysctl vm.drop_caches=3dd if=/a400-100g/netapp-
ra/resnet/data/preprocessed_data/train.rec of=/dev/null bs=512k
count=2048Results (average of 5 runs):
Local storage: 1.7 GB/s Network storage: 1.5 GB/s.
```

Beide Werte sind ähnlich. Sie zeigen, dass Netzwerk-Storage Daten zu einer Rate liefern kann, die dem lokalen Storage ähnelt.

Shared Use Case: Mehrere, unabhängige, simultane Jobs

Dieser Test simulierte den erwarteten Anwendungsfall für diese Lösung: KI-Training für mehrere Jobs und mehrere Benutzer. Jeder Node führte sein eigenes Training durch, während er den Shared Netzwerk-Storage verwendete. Die Ergebnisse werden in der folgenden Abbildung dargestellt, die zeigt, dass der Lösungsfall eine hervorragende Leistung bot, bei der alle Jobs im Wesentlichen mit derselben Geschwindigkeit wie einzelne Jobs ausgeführt wurden. Der Gesamtdurchsatz skalierte sich linear mit der Anzahl der Nodes.

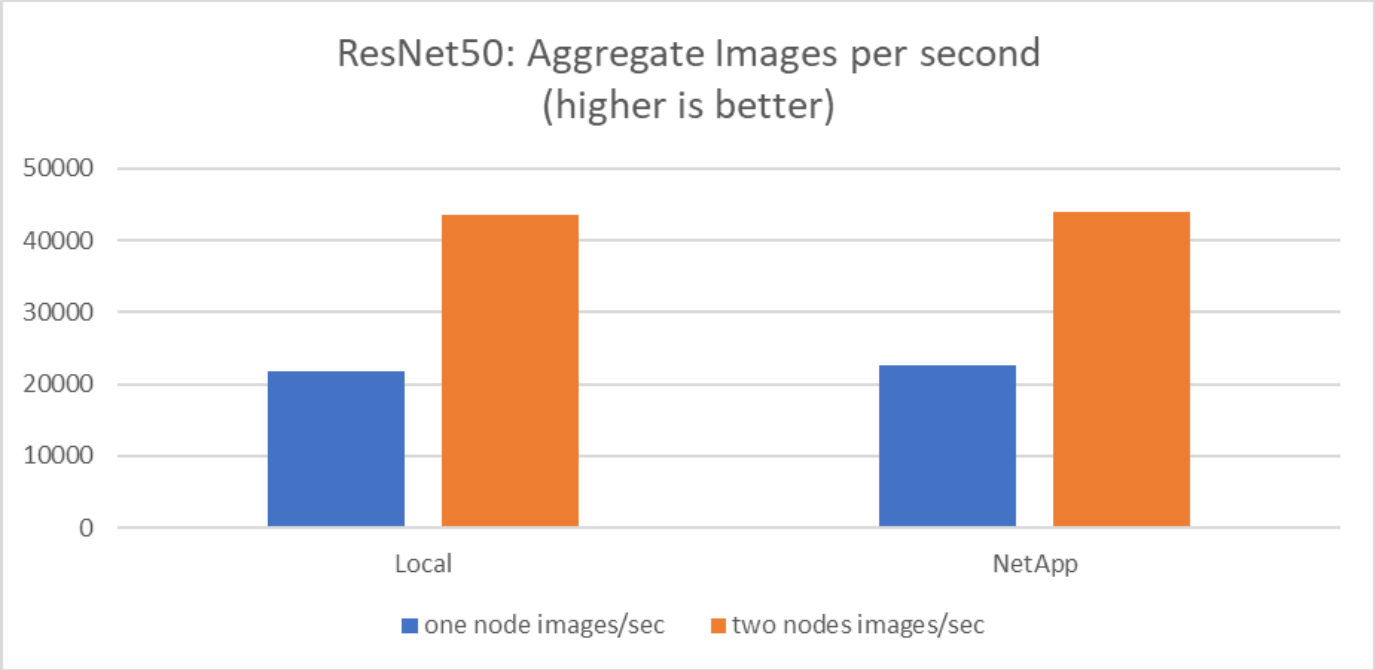

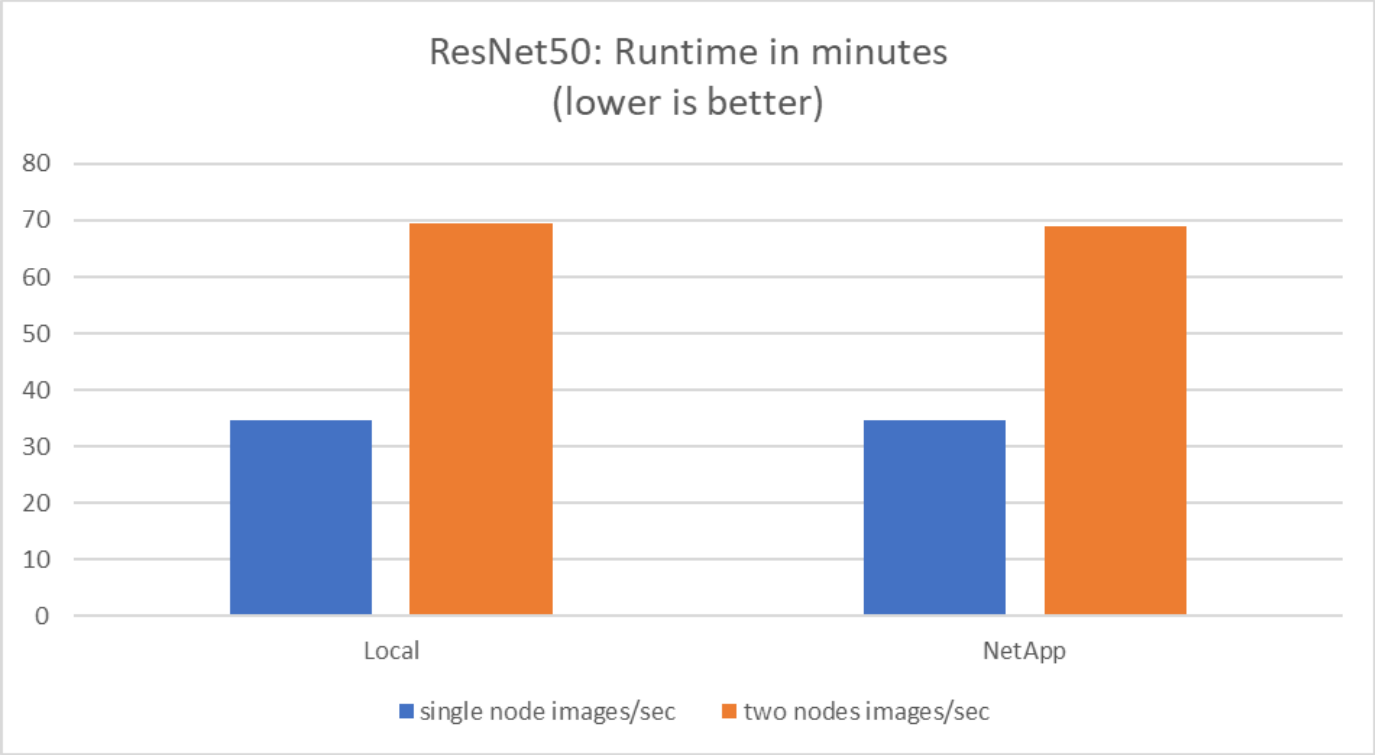

Diese Diagramme stellen die Laufzeit in Minuten dar und die Aggregat-Images pro Sekunde für Computing-Nodes, die acht GPUs von jedem Server im 100-GbE-Client-Netzwerk verwendet haben, wobei sowohl das Modell für gleichzeitige Trainings als auch das zentrale Trainingsmodell kombiniert werden. Die

durchschnittliche Laufzeit des Trainingsmodells betrug 35 Minuten und 9 Sekunden. Die einzelnen Laufzeiten waren 34 Minuten und 32 Sekunden, 36 Minuten und 21 Sekunden, 34 Minuten und 37 Sekunden, 35 Minuten und 25 Sekunden und 34 Minuten und 31 Sekunden. Die durchschnittlichen Images pro Sekunde für das Trainingsmodell betrug 22,573, die einzelnen Bilder pro Sekunde waren 21,764, 23,438, 22,556, 22,564 und 22,547.

Unsere Validierung basiert darauf, dass ein unabhängiges Trainingsmodell mit einer NetApp Datenlaufzeit von 34 Minuten und 54 Sekunden bei 22,231 Bildern/Sek. betrug Ein unabhängiges Trainingsmodell mit einer lokalen Daten-das-Laufzeit (Local Data, das) betrug 34 Minuten und 21 Sekunden bei 22,102 Bildern/Sek. Während dieser Ausführung war die durchschnittliche GPU-Auslastung 96 %, wie bei nvidia-smi zu beobachten. Zu beachten ist, dass dieser Durchschnitt die Testphase umfasst, in der GPUs nicht verwendet wurden, während die CPU-Auslastung 40 % betrug, wie mit mpstat gemessen. Dadurch wird gezeigt, dass die Datenbereitstellungsrate in jedem Fall ausreichend ist.

Anpassungen der Architektur

Das für diese Validierung verwendete Setup kann an andere Anwendungsfälle angepasst werden.

CPU-Anpassungen

Für diese Validierung wurde ein Skylake Intel Xeon Platinum 8360Y Prozessor verwendet, wie von Lenovo empfohlen. Wir gehen davon aus, dass die entsprechende Cascade Lake CPU, ein Intel Xeon Gold 6330 Prozessor, eine ähnliche Performance bieten würde, da die CPU nicht gebunden ist.

Storage-Kapazität Steigt

Sie können den Share Storage (NFS-Volume) ganz nach Bedarf erhöhen, vorausgesetzt, Sie haben die zusätzlichen Platten-Shelves und Controller-Modelle. Sie können dies über die CLI oder über die NetApp Web-Schnittstelle des Storage Controllers als Admin-Benutzer durchführen.

Schlussfolgerung

Die hier validierte NetApp und Lenovo Lösung ist eine flexible Scale-out-Architektur, die sich ideal für den Einstieg in Enterprise-KI eignet.

NetApp Storage bietet die gleiche oder bessere Performance wie lokaler SSD-Storage und bietet Datenanalysten, Data Engineers und IT-Entscheidungsträgern folgende Vorteile:

- Problemlose gemeinsame Nutzung von Daten zwischen KI-Systemen, Big-Data-Analysen und anderen geschäftskritischen Systemen Diese gemeinsame Nutzung von Daten verringert den Infrastruktur-Overhead, verbessert die Performance und optimiert das Datenmanagement im gesamten Unternehmen.
- Unabhängiges skalierbares Computing und Storage-System, um Kosten zu minimieren und die Ressourcenauslastung zu verbessern.
- Optimierte Entwicklungs- und Implementierungs-Workflows mithilfe integrierter Snapshots und Klone für sofortige und platzsparende Benutzer-Workspaces, integrierte Versionskontrolle und automatisierte Implementierung
- Datensicherung der Enterprise-Klasse für Disaster Recovery und Business Continuance.

Danksagungen

- Karthikeyan Nagalingam, Technical Marketing Engineer, NetApp
- Jarrett Upton, Admin, AI Lab Systems, Lenovo

Wo Sie weitere Informationen finden

Weitere Informationen zu den in diesem Dokument beschriebenen Daten finden Sie in den folgenden Dokumenten bzw. auf den folgenden Websites:

- Produktseite zu NetApp All-Flash-Arrays

  "https://www.netapp.com/us/products/storage-systems/all-flash-array/aff-a-series.aspx"

- Seite „NetApp AFF A400“

  "https://docs.netapp.com/us-en/ontap-systems/a400/index.html"

- Produktseite für NetApp ONTAP Datenmanagement-Software

  "http://www.netapp.com/us/products/data-management-software/ontap.aspx"

- MLPerf

  "https://mlperf.org"

- TensorFlow-Benchmark

  "https://github.com/tensorflow/benchmarks"

- NVIDIA SMI (nvidia-smi)

  "https://developer.nvidia.com/nvidia-system-management-interface"

Copyright-Informationen

Copyright © 2024 NetApp. Alle Rechte vorbehalten. Gedruckt in den USA. Dieses urheberrechtlich geschützte Dokument darf ohne die vorherige schriftliche Genehmigung des Urheberrechtsinhabers in keiner Form und durch keine Mittel – weder grafische noch elektronische oder mechanische, einschließlich Fotokopieren, Aufnehmen oder Speichern in einem elektronischen Abrufsystem – auch nicht in Teilen, vervielfältigt werden.

Software, die von urheberrechtlich geschütztem NetApp Material abgeleitet wird, unterliegt der folgenden Lizenz und dem folgenden Haftungsausschluss:

DIE VORLIEGENDE SOFTWARE WIRD IN DER VORLIEGENDEN FORM VON NETAPP ZUR VERFÜGUNG GESTELLT, D. H. OHNE JEGLICHE EXPLIZITE ODER IMPLIZITE GEWÄHRLEISTUNG, EINSCHLIESSLICH, JEDOCH NICHT BESCHRÄNKT AUF DIE STILLSCHWEIGENDE GEWÄHRLEISTUNG DER MARKTGÄNGIGKEIT UND EIGNUNG FÜR EINEN BESTIMMTEN ZWECK, DIE HIERMIT AUSGESCHLOSSEN WERDEN. NETAPP ÜBERNIMMT KEINERLEI HAFTUNG FÜR DIREKTE, INDIREKTE, ZUFÄLLIGE, BESONDERE, BEISPIELHAFTE SCHÄDEN ODER FOLGESCHÄDEN (EINSCHLIESSLICH, JEDOCH NICHT BESCHRÄNKT AUF DIE BESCHAFFUNG VON ERSATZWAREN ODER -DIENSTLEISTUNGEN, NUTZUNGS-, DATEN- ODER GEWINNVERLUSTE ODER UNTERBRECHUNG DES GESCHÄFTSBETRIEBS), UNABHÄNGIG DAVON, WIE SIE VERURSACHT WURDEN UND AUF WELCHER HAFTUNGSTHEORIE SIE BERUHEN, OB AUS VERTRAGLICH FESTGELEGTER HAFTUNG, VERSCHULDENSUNABHÄNGIGER HAFTUNG ODER DELIKTSHAFTUNG (EINSCHLIESSLICH FAHRLÄSSIGKEIT ODER AUF ANDEREM WEGE), DIE IN IRGENDEINER WEISE AUS DER NUTZUNG DIESER SOFTWARE RESULTIEREN, SELBST WENN AUF DIE MÖGLICHKEIT DERARTIGER SCHÄDEN HINGEWIESEN WURDE.

NetApp behält sich das Recht vor, die hierin beschriebenen Produkte jederzeit und ohne Vorankündigung zu ändern. NetApp übernimmt keine Verantwortung oder Haftung, die sich aus der Verwendung der hier beschriebenen Produkte ergibt, es sei denn, NetApp hat dem ausdrücklich in schriftlicher Form zugestimmt. Die Verwendung oder der Erwerb dieses Produkts stellt keine Lizenzierung im Rahmen eines Patentrechts, Markenrechts oder eines anderen Rechts an geistigem Eigentum von NetApp dar.

Das in diesem Dokument beschriebene Produkt kann durch ein oder mehrere US-amerikanische Patente, ausländische Patente oder anhängige Patentanmeldungen geschützt sein.

ERLÄUTERUNG ZU „RESTRICTED RIGHTS“: Nutzung, Vervielfältigung oder Offenlegung durch die US-Regierung unterliegt den Einschränkungen gemäß Unterabschnitt (b)(3) der Klausel „Rights in Technical Data – Noncommercial Items“ in DFARS 252.227-7013 (Februar 2014) und FAR 52.227-19 (Dezember 2007).

Die hierin enthaltenen Daten beziehen sich auf ein kommerzielles Produkt und/oder einen kommerziellen Service (wie in FAR 2.101 definiert) und sind Eigentum von NetApp, Inc. Alle technischen Daten und die Computersoftware von NetApp, die unter diesem Vertrag bereitgestellt werden, sind gewerblicher Natur und wurden ausschließlich unter Verwendung privater Mittel entwickelt. Die US-Regierung besitzt eine nicht ausschließliche, nicht übertragbare, nicht unterlizenzierbare, weltweite, limitierte unwiderrufliche Lizenz zur Nutzung der Daten nur in Verbindung mit und zur Unterstützung des Vertrags der US-Regierung, unter dem die Daten bereitgestellt wurden. Sofern in den vorliegenden Bedingungen nicht anders angegeben, dürfen die Daten ohne vorherige schriftliche Genehmigung von NetApp, Inc. nicht verwendet, offengelegt, vervielfältigt, geändert, aufgeführt oder angezeigt werden. Die Lizenzrechte der US-Regierung für das US-Verteidigungsministerium sind auf die in DFARS-Klausel 252.227-7015(b) (Februar 2014) genannten Rechte beschränkt.

Markeninformationen

NETAPP, das NETAPP Logo und die unter http://www.netapp.com/TM aufgeführten Marken sind Marken von NetApp, Inc. Andere Firmen und Produktnamen können Marken der jeweiligen Eigentümer sein.